

Phase 1 — Chaque décision expliquée

Statistical arbitrage : univers, données et absence de fuite

Projet *stat-arb* régime-aware & sélection honnête

Utilities du S&P 500 — 2014-2026

Document de référence pour la défense orale

1. À quoi sert ce document

Ce document reprend **chaque décision** prise pendant la Phase 1 du projet et l'explique en détail : ce qu'on a décidé, pourquoi, quelles étaient les alternatives, et ce qu'on perd en choisissant. Il est écrit pour que tu puisses défendre le projet au tableau sans notes.

La Phase 1 ne produit aucun signal, aucun backtest, aucun P&L. Elle produit uniquement un **univers de titres et une série de prix**. C'est pour cette raison qu'elle paraît anodine — et c'est exactement pour cette raison qu'elle est dangereuse : une erreur commise ici ne provoque jamais de message d'erreur. Elle produit un backtest qui tourne, qui affiche un Sharpe, et qui est faux. Toutes les phases suivantes héritent silencieusement de ses défauts.

La règle qui structure toute la Phase 1

Un backtest ne peut utiliser, à la date t , que de l'information réellement disponible à la date t . Toute violation de cette règle s'appelle une **fuite** (*look-ahead bias*), et une fuite gonfle la performance sans jamais se signaler.

La difficulté est que les fuites les plus graves ne se cachent pas dans le signal. Elles se cachent dans la construction des données — c'est-à-dire ici.

Le document se lit dans l'ordre. Les sections 2 et 3 posent le vocabulaire (à sauter si tu es à l'aise avec la cointégration). Les sections 4 à 9 détaillent les décisions. La section 10 répond aux deux questions posées à la fin de la Phase 1. La section 11 est un glossaire.

2. Le vocabulaire, sans raccourci

2.1 Ce qu'est une paire

Une *paire* est un couple d'actions (A, B) qu'on trade **ensemble et en sens opposés** : on achète A et on vend B à découvert, ou l'inverse. On ne parie jamais sur la direction du marché, mais sur **l'écart** entre les deux titres.

Cet écart s'appelle le **spread**. Sa définition la plus simple :

$$s(t) = \log P_A(t) - \beta \cdot \log P_B(t)$$

Le coefficient β s'appelle le **ratio de couverture** (*hedge ratio*). Il répond à la question : « pour un dollar investi en A, combien faut-il vendre de B pour neutraliser le risque commun ? » Si $\beta = 1,3$, on vend 1,3 dollar de B pour chaque dollar de A.

On travaille sur les **log-prix** et non sur les prix bruts pour deux raisons. D'abord, la différence de log-prix est une quantité sans dimension (un log-ratio), donc comparable entre paires de niveaux de prix très différents. Ensuite, les rendements sont additifs en log, ce qui rend le calcul du P&L direct.

2.2 La stratégie en une phrase

Si le spread est **stationnaire** — c'est-à-dire s'il oscille autour d'une moyenne fixe au lieu de partir à la dérive — alors quand il s'écarte anormalement de cette moyenne, on parie qu'il y reviendra. On vend le spread quand il est haut, on l'achète quand il est bas, et on ferme au retour à la moyenne.

Toute la stratégie repose donc sur **une seule hypothèse** : la stationnarité du spread. La Phase 2 la testera, la Phase 3 corrigera le fait qu'on la teste des centaines de fois, et la Phase 4 traitera le fait qu'elle cesse d'être vraie sans prévenir.

2.3 Corrélation et cointégration : la distinction qui tombe en entretien

C'est **la** question de base sur ce projet. Deux séries peuvent être fortement corrélées sans être cointégrées, et inversement.

La **corrélation** porte sur les *rendements*, c'est-à-dire sur les variations de court terme. Dire que A et B sont corrélés à 0,9 signifie que leurs mouvements quotidiens vont dans le même sens. Cela ne dit **rien** sur l'écart de leurs niveaux à long terme : deux titres peuvent monter et descendre ensemble tous les jours tout en s'éloignant indéfiniment l'un de l'autre.

La **cointégration** porte sur les *niveaux*. Elle dit qu'il existe un β tel que la combinaison $\log P_A - \beta \log P_B$ soit stationnaire, alors que $\log P_A$ et $\log P_B$ pris séparément ne le sont pas.

Formellement : un prix d'action se comporte comme une série **intégrée d'ordre 1**, notée $I(1)$ — sa différence (le rendement) est stationnaire, mais son niveau dérive sans borne. La cointégration est le cas remarquable où une combinaison linéaire de deux séries $I(1)$ est $I(0)$, c'est-à-dire stationnaire.

L'intuition à donner au tableau

Deux séries $I(1)$ cointégrées partagent la **même tendance stochastique**. Le β est le poids exact qui l'élimine par soustraction : ce qui reste est le bruit stationnaire autour de la relation d'équilibre.

L'image classique : un homme ivre et son chien. Chacun marche au hasard (chaque trajectoire est $I(1)$, imprévisible). Mais la laisse borne leur distance : cette distance est stationnaire. La corrélation décrit s'ils font le même pas au même instant ; la cointégration décrit l'existence de la laisse.

Conséquence directe pour ce projet : la cointégration n'est pas une coïncidence statistique, elle exige un **mécanisme économique** qui joue le rôle de la laisse. C'est cet argument, et lui seul, qui justifie la décision de la section 4.

3. Pourquoi la Phase 1 mérite un document entier

Le pairs trading a une réputation détestable auprès des fonds quantitatifs, et pour une bonne raison : c'est l'exercice où il est le plus facile de produire un backtest spectaculaire et entièrement faux. Trois mécanismes y suffisent, et tous les trois se jouent en Phase 1 ou juste après.

1. **Le survivorship bias.** On construit l'univers avec les sociétés qui existent aujourd'hui, donc on ne trade que des survivants.
2. **Le multiple testing.** On teste des centaines de paires et on garde les meilleures, sans corriger le fait qu'en testant assez, on trouve toujours.
3. **Le look-ahead d'exécution ou de normalisation.** On utilise, pour décider à la date t , une statistique calculée sur des données postérieures à t .

Le point 2 est traité en Phase 3, le point 3 en Phases 2 et 6. **Le point 1 se joue entièrement en Phase 1**, et c'est le seul qu'on ne peut plus corriger après coup : si l'univers est mal construit, tout ce qui suit est contaminé.

Ce qui rend ces erreurs particulières

Un bug informatique classique s'annonce : le programme s'arrête, une exception est levée, un test échoue. Les erreurs de Phase 1 ne font rien de tout cela.

Elles produisent un backtest qui s'exécute normalement, des courbes lisses et un ratio de Sharpe présentable. La seule façon de les détecter est de les chercher délibérément, en écrivant des contrôles dont l'unique fonction est de les faire échouer.

4. Décision n°1 — L'univers : les utilities du S&P 500

4.1 Première sous-décision : rester à l'intérieur d'un seul secteur

On aurait pu former les paires sur l'ensemble du S&P 500. On a choisi de restreindre à un secteur GICS unique. Deux justifications, de nature différente.

Justification économique

La section 2.3 a établi que la cointégration exige une tendance stochastique commune. À l'intérieur d'un secteur, on peut la nommer : pour les utilities, c'est l'exposition aux taux longs (ce sont des actifs à durée très élevée, achetés pour leur rendement), le régime réglementaire (les tarifs sont fixés par des commissions sur une base d'actifs) et les coûts d'input (gaz, combustibles). Entre deux secteurs, ce mécanisme n'existe pas — une cointégration entre une banque et un producteur de semi-conducteurs serait un artefact d'échantillon.

Justification statistique

Le nombre de paires croît en N^2 . Sur 500 titres, on aurait $500 \times 499 / 2 = 124\,750$ tests à corriger. Avec une correction de Bonferroni, le seuil deviendrait $\alpha/124750 \approx 4 \times 10^{-7}$: plus aucune paire ne passerait, et la Phase 3 n'aurait rien à montrer. Restreindre le secteur ramène le problème à une échelle où la correction est **contraignante mais pas destructrice** — 465 tests.

C'est un point important pour l'entretien : la restriction sectorielle n'est pas une facilité destinée à réduire le travail. C'est une **réduction de l'espace de recherche fondée sur un prior**, et c'est précisément ce que fait un chercheur quantitatif sérieux avant de lancer un screener.

4.2 Deuxième sous-décision : lequel des onze secteurs

Quatre critères ont été posés **avant** de regarder les données, ce qui est l'élément décisif : choisir le secteur après avoir vu quel secteur donne le meilleur P&L serait du multiple testing au niveau du secteur, et détruirait l'argument même du projet.

Critère	Ce qu'il exige	Pourquoi
Facteur commun identifiable	Pouvoir nommer le mécanisme économique qui lie les titres	Sans lui, la cointégration détectée est un artefact d'échantillon
Taille suffisante	Au moins ~25 titres, soit ≥ 300 paires	En dessous, la démonstration sur les tests multiples n'a plus de poids
Rupture datable et explicable	Au moins un épisode où la relation casse, dont on connaît la cause	La V1 doit expliquer <i>pourquoi</i> ça casse, pas seulement constater
Homogénéité d'exécution	Un seul marché, une seule devise, une seule heure de clôture	Évite la prédictibilité illusoire due à l'asynchronicité des clôtures

Les quatre critères de sélection du secteur, figés avant tout examen des données.

Les utilities satisfont les quatre. Le facteur commun est le plus net de tout le marché actions américain. Le secteur compte entre 25 et 31 titres selon la date. Et il offre non pas une mais **trois ruptures racontables** :

- **Mars 2020, COVID.** Choc de liquidité généralisé : toutes les corrélations convergent vers 1, les relations de long terme sont temporairement noyées.
- **2022, choc de taux.** La remontée rapide des taux frappe les utilities via leur durée, mais **de façon inégale** selon le niveau d'endettement et la structure de dette de chaque société. La dispersion des sensibilités casse des relations qui tenaient depuis des années.

- **2023-2024, repricing IA.** La demande électrique des centres de données revalorise brutalement les producteurs *merchant* — ceux qui vendent au prix de marché (VST, CEG, NRG) — tandis que les régulés (ED, WEC) restent plafonnés par leur tarification. C'est une rupture **structurelle** : les deux groupes cessent définitivement de partager la même tendance.

La rupture de 2023-2024 est le cœur narratif de la V1

Elle a tout ce qu'un interviewer veut entendre : une date, un mécanisme économique précis, une conséquence statistique vérifiable (le β dérive, la demi-vie explose, la p-value de l'ADF remonte), et un caractère **permanent** — ce n'est pas un choc temporaire dont il faut attendre la fin, c'est une relation qui n'existe plus et dont il faut sortir.

4.3 Ce qu'on a écarté, et pourquoi

Secteur	Ce qu'il apportait	Pourquoi écarté
Banques régionales (KRE)	~90-140 noms, donc ~4 000 paires : tests multiples bien plus spectaculaires. Et mars 2023 (SVB, Signature, First Republic) fait du survivorship bias le sujet central plutôt qu'une note de bas de page.	Les prix des sociétés en faillite sont introuvables gratuitement. Le budget serait passé en plomberie de données au lieu de méthodologie.
Énergie E&P (XOP)	Facteur commun évident (le prix du pétrole) et rupture de 2020 spectaculaire, avec un WTI négatif en avril.	La vague de fusions-acquisitions de 2023-2024 tronque un grand nombre de séries. L'hétérogénéité des niveaux d'endettement fragilise la cointégration.
Semi-conducteurs	La rupture IA de 2023 est extrêmement visible.	Secteur trop tendanciel : risque réel de ne trouver quasiment aucune paire cointégrée, ce qui viderait la Phase 3 de tout contenu.

4.4 L'objection que tu vas recevoir

« Ton spread n'est qu'un pari de durée déguisé »

L'objection est sérieuse et partiellement fondée : si tous les titres réagissent aux taux, un long/short entre deux d'entre eux reste exposé au différentiel de sensibilité aux taux.

La bonne réponse n'est pas de nier, c'est de mesurer. Le β de couverture absorbe par construction l'exposition *commune*. Ce qui doit être vérifié, c'est que le **résidu** — donc le P&L — n'est plus explicable par les taux. Le test est explicite : régresser les rendements quotidiens de la stratégie sur les variations du taux 10 ans américain et montrer que le coefficient n'est pas significatif. C'est prévu en Phase 7.

Répondre « je ne sais pas, mais voici le test que je ferais » vaut infiniment mieux que de nier l'objection.

5. Décision n°2 — La période et le découpage temporel

5.1 Pourquoi 2014 → 2026

Le choix de la période résulte d'un arbitrage entre deux forces opposées.

Allonger l'historique augmente le nombre de sous-périodes indépendantes, donc la fiabilité des conclusions : avec trois ans de données on ne peut rien dire de la stabilité d'une stratégie. **Raccourcir** l'historique améliore la qualité des données (le survivorship s'aggrave en remontant) et la pertinence (la structure du secteur en 2010 — avant l'essor des renouvelables, avant la scission de Constellation — ressemble peu à celle d'aujourd'hui).

Douze ans et demi place le curseur là où les deux effets s'équilibrent : assez de sous-périodes pour parler de dégradation du signal, pas assez pour tester une stratégie sur un secteur qui n'existe plus.

5.2 Le walk-forward : trois ans de sélection, un an de trading

C'est le protocole qui garantit que la sélection des paires et leur trading n'ont jamais lieu sur les mêmes données.

```
fold 1 : SELECTION 2014-2016 (3 ans) -> TRADING 2017 (1 an)
fold 2 : SELECTION 2015-2017          -> TRADING 2018
fold 3 : SELECTION 2016-2018          -> TRADING 2019
...
fold 9 : SELECTION 2022-2024          -> TRADING 2025
```

A chaque fold : univers point-in-time recalculé, filtre de liquidité recalculé, cointégration retestée, paires sélectionnées -- puis FIGEES.
La fenêtre de trading n'influence JAMAIS la sélection qui la précède.

Pourquoi trois ans de sélection ? Un test de cointégration a besoin de suffisamment de points pour distinguer une vraie relation d'équilibre d'un hasard : environ 750 jours de bourse. Sur un an, le test de Dickey-Fuller augmenté n'a quasiment aucune puissance — il ne rejette presque jamais l'hypothèse de non-stationnarité, même quand elle est fausse.

Pourquoi un an de trading ? Au-delà, on suppose implicitement que la relation sélectionnée en 2016 tient encore en 2020. C'est exactement l'hypothèse que la V1 conteste. Un an est le compromis entre la fréquence de re-sélection et le coût de rotation.

Le piège dans lequel il ne faut pas tomber

Il est tentant, une fois arrivé en période de trading, de re-tester la cointégration et de ne garder que les paires qui « fonctionnent encore ». C'est une **réintroduction directe du look-ahead** : on utiliserait l'information de la période de trading pour décider quoi trader pendant cette même période.

La règle est absolue : **la sélection est figée à la fin de l'in-sample**. Si une paire se dégrade pendant le trading, c'est le mécanisme de détection de régime (V1) qui doit la sortir — et ce mécanisme ne regarde, lui aussi, que le passé.

6. Décision n°3 — Quels prix exactement

6.1 Prix bruts, ajustés des splits, ou total-return ?

Trois séries de prix différentes existent pour une même action, et le choix entre elles n'est pas cosmétique.

- Le **prix brut** est le prix affiché à l'écran. Il chute mécaniquement le jour d'un split ou du détachement d'un dividende.
- Le **prix ajusté des splits** corrige les divisions d'actions.
- Le **prix total-return** corrige splits *et* dividendes : il représente la valeur d'un investissement qui réinvestit ses dividendes.

On a retenu le total-return. Voici la démonstration, car c'est le genre d'argument qui distingue immédiatement un candidat sérieux.

Pourquoi c'est décisif spécifiquement pour les utilities

Les utilities versent 3 à 4 % de dividende par an, et surtout ce rendement est **très dispersé** d'un titre à l'autre. Notons δ_A et δ_B les rendements de dividende annuels de deux titres. Le prix brut décroche du prix total-return d'un facteur qui croît avec le temps :

$$\log P^{\text{brut}}(t) \approx \log P^{\text{TR}}(t) - \delta \cdot t$$

Le spread calculé sur prix bruts contient donc un terme $-(\delta_A - \beta \delta_B) \cdot t$: **une dérive linéaire déterministe**. Or une série qui dérive linéairement n'est pas stationnaire. Le test ADF la rejettera — et on écarterait ainsi des paires **authentiquement cointégrées**, uniquement parce que leurs politiques de dividende diffèrent.

Ordre de grandeur mesuré sur l'univers réel : le rendement de dividende implicite va de **1,07 % (PCG) à 6,39 % (OKE)**, soit 5,3 points d'écart entre deux titres du même secteur. Un écart de 2 points par an injecte déjà environ 6 % de dérive sur une fenêtre de sélection de trois ans — du même ordre que l'amplitude du spread lui-même. L'effet n'est pas marginal.

L'expérience, et ce qu'elle autorise réellement à conclure

On a testé les 465 paires sur une fenêtre in-sample type (2016-2018), une fois sur prix total-return, une fois sur prix bruts, et comparé les **sélections** obtenues :

```
465 paires testees sur 2016-2018 (Engle-Granger, seuil 5 %)

significatives sur TOTAL-RETURN : 112
significatives sur PRIX BRUTS    : 137
desaccord : 51 paires (11 %) -- 13 perdues, 38 creees

mais l'essentiel est un alea de p-value pres du seuil :
    perdues : 11/13 marginales (85 %)
    creees  : 26/38 marginales (68 %)

BASCULEMENTS FRANCS (p > 0.15 d'un cote, < 0.05 de l'autre)
    paires FABRIQUEES par les prix bruts : 16
    paires DETRUITES  par les prix bruts : 1
```

Il faut lire ce résultat avec précaution, et c'est un point de méthode important. La conclusion tentante — « les prix bruts fabriquent 38 fausses paires » — n'est pas soutenable : 68 % de ces paires ont une p-value dans l'intervalle [0,03 ; 0,08]. Elles basculent parce qu'une p-value proche du seuil est bruitée, pas parce que la dérive de dividende aurait changé quoi que ce soit de substantiel. Les compter comme des erreurs de sélection serait malhonnête.

Ce qui résiste, c'est l'asymétrie des basculements francs : 16 contre 1. Seize paires sans relation d'équilibre sur les prix économiquement corrects deviennent franchement significatives dès qu'on utilise les prix bruts ; une seule bascule dans l'autre sens. La corrélation entre l'ampleur de la dérive et l'écart de p-value vaut 0,29 — le mécanisme est là, mais il n'explique qu'une partie du phénomène.

Le mécanisme, pour les cas francs. Si deux titres divergent économiquement mais que celui qui monte le plus verse aussi le plus de dividende, la dérive **annule** la divergence sur prix bruts. Le spread devient artificiellement plat, donc « stationnaire » au sens du test.

La formulation à retenir

Les deux séries de prix produisent des sélections qui diffèrent sur 11 % des paires. Dire « 38 fausses paires » serait exagéré — l'essentiel est du bruit de seuil. Mais l'asymétrie **16 contre 1** est robuste : les prix bruts fabriquent de la cointégration apparente bien plus souvent qu'ils n'en détruisent.

Le choix de la série de prix n'est pas un détail de préparation des données : **c'est une décision qui change la sélection elle-même.**

Savoir distinguer « ce que je voudrais conclure » de « ce que mes données autorisent » est précisément ce qu'un fonds cherche à tester en entretien.

6.2 Pourquoi on ne remplit jamais les prix manquants

Quand une série a un trou — jour férié partiel, suspension de cotation, défaut du fournisseur — le réflexe universel est le *forward-fill* : reporter le dernier prix connu. On ne le fait pas ici. Mais la raison n'est pas celle qu'on lit partout, et cette section mérite d'être lue attentivement parce qu'elle contient une **erreur commise puis corrigée**.

L'argument habituel — et pourquoi il est faux

L'argument que l'on trouve dans la plupart des tutoriels, et que j'ai moi-même avancé avant de le tester, est le suivant : reporter un prix crée un rendement nul suivi d'un rattrapage, donc la séquence « pas de mouvement puis mouvement compensatoire », c'est-à-dire la signature du retour à la moyenne. Le forward-fill fabriquerait donc le signal que la stratégie cherche.

C'est faux, et la simulation le montre sans ambiguïté. On simule une marche aléatoire pure — donc sans aucun retour à la moyenne — on y introduit 5 % de jours manquants, on applique un forward-fill, et on teste :

Marche aleatoire pure, 400 simulations, 5 % de jours manquants

```
taux de rejet ADF a 5 %   sans ffill :    6.8 %
taux de rejet ADF a 5 %   avec ffill  :    6.5 %
autocorr. lag-1 des diffs sans ffill : -0.0016
autocorr. lag-1 des diffs avec ffill  : -0.0017
```

Aucun effet. Et sur un spread réellement mean-reverting (processus d'Ornstein-Uhlenbeck de demi-vie 15 jours), le forward-fill ne biaise ni la demi-vie estimée (+0,2 %) ni le nombre de signaux générés (67,6 contre 67,8).

La raison est simple une fois qu'on la voit : le forward-fill **redistribue** les incréments sans les modifier. Le jour manquant porte un rendement nul, le jour suivant porte la somme des deux incréments. La somme totale est inchangée, et comme les incréments sont indépendants, la covariance entre rendements consécutifs reste nulle. Il n'y a pas de « rattrapage compensatoire » : il y a un report.

Ce que cela veut dire pour l'entretien

Si tu avances l'argument du « retour à la moyenne fabriqué » face à quelqu'un qui a déjà fait la simulation, tu perds toute crédibilité sur le reste du projet.

L'argument correct est plus simple et plus solide — et le fait de pouvoir dire « je l'ai cru, je l'ai testé, c'était faux, voici ce qui est vrai » vaut davantage que n'importe quelle justification apprise.

L'argument correct : la tradabilité

Le vrai problème du forward-fill n'est pas statistique, il est **opérationnel**. Sur un spread d'Ornstein-Uhlenbeck avec 5 % de jours manquants :


```
Spread OU (demi-vie 15 j), 5 % de jours manquants, 300 simulations
```

```
demi-vie estimee sans ffill : 13.95 j
demi-vie estimee avec ffill : 13.98 j      (biais +0.2 %)
signaux |z| > 2 sans ffill : 67.8
signaux |z| > 2 avec ffill : 67.6
```

```
signaux tombant un jour SANS COTATION : 2.6 par serie
soit 3.8 % des signaux, a un prix qui n'existe pas
```

La justification à retenir

Le forward-fill ne corrompt pas la statistique du spread : il corrompt l'**exécution**. Environ 4 % des signaux d'entrée tombent un jour où le titre ne cotait pas. Le backtest ouvre alors une position à un prix qui n'a jamais existé, puis enregistre un P&L sur cette transaction impossible.

C'est une fuite d'exécution, de la même famille que le fait de trader au cours du jour où le signal est calculé — le sujet de la Phase 6.

La décision : aucun forward-fill. Les valeurs manquantes restent des NaN et sont traitées explicitement, paire par paire, au moment du test.

6.3 Le nettoyage, et pourquoi il est volontairement minimal

Le nettoyage appliqué se réduit à deux règles, choisies pour être **non destructives** — un nettoyage agressif est lui-même une source de biais.

1. **Suppression des colonnes entièrement vides.** Ce sont les tickers pour lesquels le fournisseur ne sert plus rien, typiquement des sociétés délistées. On ne les efface pas de la mémoire du projet : ils sont comptabilisés dans le rapport de survivorship (section 9).
2. **Suppression des dates où moins de 80 % des titres *en vie* cotent.** Ce sont des jours fériés partiels ou des incidents de données, pas des séances. Le point subtil est le dénominateur : on compare au nombre de titres **en vie à cette date**, et non au nombre total de colonnes. Sinon, un titre introduit en 2022 ferait échouer le critère sur toutes les séances de 2014 à 2021 et on supprimerait huit ans de données valides.

7. Décision n°4 — L'univers point-in-time

7.1 Le problème : pourquoi le survivorship est une fuite

Prendre les constituants **actuels** d'un indice et remonter leur historique est la méthode employée dans l'immense majorité des projets étudiants. Elle est fautive, et la raison est plus profonde qu'un simple « biais ».

Sélectionner aujourd'hui les sociétés membres du S&P 500 revient à utiliser une information datée d'aujourd'hui — **le fait que ces sociétés existent encore et sont assez grandes pour figurer dans l'indice** — afin de décider quoi trader en 2015. C'est structurellement identique à un look-ahead sur le signal. La seule différence est que la variable qui fuit n'est pas un prix futur : c'est la **survie**.

L'effet est systématique et va toujours dans le même sens : on exclut précisément les sociétés qui ont fait faillite, ont été rachetées ou ont décroché — c'est-à-dire les cas où une relation de cointégration se brise violemment. On mesure donc la performance de la stratégie sur un échantillon amputé de ses pires scénarios.

7.2 Deux méthodes possibles, et pourquoi on a changé

Méthode A — reconstruire par les changements. On part de la liste actuelle et on remonte le temps en inversant chaque ajout et chaque retrait consignés dans une table historique. C'est ce qui était prévu initialement.

Cette table n'existant plus sur la source publique, on a basculé sur une **méthode B, qui s'avère strictement supérieure** : lire l'historique des révisions de la page. La page listant les constituants du S&P 500 est éditée en continu depuis plus de quinze ans, et chaque version passée reste accessible. On récupère donc la page **telle qu'elle existait** à chaque date de sélection.

	Méthode A — table des changements	Méthode B — révisions (retenue)
Principe	Inverser les changements depuis aujourd'hui	Lire la page telle qu'elle était à la date voulue
Secteur GICS	Perdu pour les sociétés sorties : la table ne consigne que le ticker, il faudrait réattribuer le secteur à la main	Observé directement , tel qu'il était classé à l'époque
Reclassifications	Invisibles : un titre reclassé d'un secteur à l'autre n'apparaît pas comme un changement d'indice	Capturées automatiquement (cas ONEOK, section 8.4)
Robustesse	Une erreur dans la table se propage à toutes les dates antérieures	Chaque date est lue indépendamment : une erreur reste locale

La bascule vers la méthode B n'était pas un pis-aller : elle donne l'appartenance *et* le secteur point-in-time, tous deux directement observés.

7.3 Le détail technique qui garantit l'absence de fuite

Toute la propriété anti-fuite tient dans un paramètre de la requête :

```
params = {
  "rvstart": timestamp,    # la date de sélection
  "rvdir":   "older",      # <-- REMONTER dans le temps depuis cette date
  "rvlimit": 1,
}
```

`rvdir="older"` demande la dernière révision publiée **avant** la date de sélection. Avec `"newer"`, on obtiendrait la première révision publiée *après* — donc une page pouvant déjà refléter des changements d'indice postérieurs à la date de décision. Un seul mot sépare une reconstruction correcte d'une fuite.

Le décalage observé entre la date de sélection et la révision utilisée est de **2 jours en médiane, 19 jours au maximum**. Ce décalage joue toujours dans le sens conservateur : la page utilisée est légèrement *en retard* sur la réalité, jamais en avance.

7.4 Trois sous-décisions de mise en œuvre

Cadence semestrielle

On prend une photo de l'indice tous les six mois. La re-sélection du walk-forward étant annuelle, chaque date de sélection dispose d'une photo vieille de six mois au maximum. Descendre au mensuel multiplierait par six le nombre de requêtes pour une précision dont la stratégie n'a aucun usage : elle ne rebalance qu'une fois par an.

Cache disque systématique

Chaque révision téléchargée est écrite sur disque. Ce n'est pas une optimisation, c'est une **exigence de reproductibilité** : sans cache, la construction de l'univers dépend d'une page web modifiable à tout instant, et peut même être éditée rétroactivement. Deux exécutions à un mois d'intervalle pourraient produire deux univers différents, donc deux backtests différents, sans qu'aucune ligne de code n'ait changé.

Échec bruyant en cas de requête ratée

Si une requête échoue de façon répétée, le programme lève une exception et s'arrête. La tentation serait de passer le snapshot manquant et de continuer. Ce serait précisément le type de dégradation silencieuse contre laquelle toute la Phase 1 est construite : un univers tronqué sur une période, sans que rien ne le signale.

8. Décision n°5 — Le contrôle d'identité des tickers

8.1 Ce qu'on a découvert

Une fois l'univers point-in-time construit, on a téléchargé les prix des 38 tickers. L'examen des dates de début a révélé un problème qui n'était pas anticipé et qui aurait invalidé l'intégralité du projet.

Ticker	Société membre de l'indice	Sortie	Données servies à partir de	Ce que c'est en réalité
NU	Northeast Utilities	2015	9 décembre 2021	Nu Holdings — néobanque brésilienne, IPO fin 2021
POM	Pepco Holdings	2016 (racheté par Exelon)	8 octobre 2025	Une société sans rapport, cotée depuis 2025
TE	TECO Energy	2016 (racheté par Emera)	10 janvier 2020	Une société sans rapport
TEG	Integrus Energy	2015 (racheté par WEC)	22 décembre 2015	Une société sans rapport, ticker repris quelques mois après

Les quatre cas de recyclage de ticker détectés dans l'univers.

Les tickers ne sont pas des identifiants pérennes. Quand une société disparaît, son symbole retourne au pot commun et peut être réattribué. Trois lettres n'identifient pas une entreprise — elles identifient un emplacement sur un marché à un instant donné.

Ce qui se serait passé sans ce contrôle

Le backtest aurait traité les prix d'une **néobanque brésilienne** comme ceux d'une utility américaine régulée. Il aurait testé la cointégration entre Nu Holdings et Duke Energy, l'aurait peut-être trouvée significative sur une fenêtre, et aurait ouvert des positions.

Aucune exception n'aurait été levée. Aucun test n'aurait échoué. La courbe de P&L aurait été parfaitement lisse. Et en entretien, on aurait défendu avec conviction un résultat entièrement faux.

C'est l'illustration exacte de la thèse de la section 3 : **les erreurs qui comptent ne provoquent pas d'erreur.**

8.2 La règle de détection

L'idée : on dispose de deux informations indépendantes sur chaque ticker. D'un côté, sa **fenêtre d'appartenance** au secteur, issue de la reconstruction point-in-time. De l'autre, sa **période de cotation**, issue du fournisseur de prix. Si le ticker désigne bien la même société dans les deux sources, ces deux intervalles doivent se recouvrir.

$$\text{recouvrement} = |[début cotation, fin cotation] \cap [entrée indice, sortie indice]| / |[entrée indice, sortie indice]|$$

- recouvrement **quasi nul** → le ticker désigne une autre société : RECYCLED
- recouvrement **partiel** (< 50 %) → historique tronqué, revue manuelle : SUSPECT
- recouvrement **substantiel** → identité cohérente : OK

Le contrôle est **bloquant** : les tickers classés RECYCLED, SUSPECT ou NO_DATA sont retirés de l'univers tradable, et la liste des exclusions est écrite dans un rapport auditable.

8.3 Les deux bugs rencontrés en écrivant ce contrôle

Ils méritent d'être racontés, parce qu'ils illustrent que même un contrôle anti-erreur doit lui-même être vérifié.

Bug n°1 — le faux positif ONEOK

La première version classait `ONE` comme recyclé. Or ONEOK est bien la même société, avec un historique complet. L'erreur venait de la définition de la fenêtre d'appartenance : `[premier snapshot membre, dernier snapshot membre]`. ONEOK n'apparaissant que dans **un seul** snapshot — il a été reclassé de *Utilities* vers *Energy* par GICS début 2014 — sa fenêtre avait une durée nulle, et le recouvrement divisait par zéro.

Correction : être membre à la date t signifie l'être au moins jusqu'à la photo suivante. La fenêtre est donc élargie de six mois à droite. Le cas ONEOK est d'ailleurs intéressant en soi : c'est une **reclassification sectorielle**, que la méthode B capture automatiquement alors que la méthode A l'aurait totalement manquée.

Bug n°2 — le seuil à zéro exact

La règle initiale déclarait recyclé un recouvrement **exactement nul**. TEG a un recouvrement de 0,014 : Integrys a été racheté en juin 2015 et le ticker réattribué dès décembre 2015, si bien que les deux intervalles se chevauchent de dix jours. Avec un seuil à zéro, TEG passait entre les mailles.

Correction : seuil à 5 %. La leçon générale est qu'un test binaire fondé sur une égalité exacte est fragile — il faut une marge, et il faut avoir regardé les données pour la calibrer.

8.4 L'angle mort qui subsiste

Le contrôle compare deux intervalles. Il détecterait donc mal un recyclage survenant **pendant** la fenêtre d'appartenance — le recouvrement resterait élevé et le statut passerait à `OK`. Ce cas n'est pas observé ici, et il est peu probable en pratique (un ticker n'est pas réattribué instantanément), mais il est documenté plutôt que passé sous silence.

Le contrôle réellement robuste utiliserait un identifiant pérenne — CUSIP, SEDOL, ou le PERMNO du CRSP — qui ne change pas quand le ticker change. C'est exactement ce que fournissent les bases professionnelles, et c'est une des raisons pour lesquelles elles coûtent cher.

9. Les résultats de la Phase 1

9.1 Les chiffres

Grandeur	Valeur	Ce qu'elle sert
Tickers en union brute	38	Tous les noms ayant appartenu au secteur sur la période
Tickers tradables	33	Après contrôle d'identité
Taille du secteur par date	25 à 31	Varie avec les entrées/sorties d'indice
Paires testables au maximum	465	$N(N-1)/2$ — la charge de tests multiples de la Phase 3
Faux positifs attendus à $\alpha = 5\%$	$\approx$ 23	Le chiffre d'ouverture de la Phase 3
Séances de bourse	3140	02/01/2014 → 29/06/2026
Photos de l'indice	25	Semestrielles, lag médian 2 jours

Le chiffre à retenir pour la Phase 3

Avec 31 titres, on teste 465 paires. Sous l'hypothèse nulle — aucune paire n'est réellement cointégrée — un test au seuil de 5 % en déclarerait tout de même **≈ 23 significatives**, par pur hasard.

Tout l'argument de la Phase 3 consiste à comparer ce nombre à celui des paires effectivement trouvées significatives. Si on en trouve 30, on n'a presque rien trouvé.

9.2 Le cas PG&E : ce que le point-in-time achète concrètement

La reconstruction montre que PCG est **hors de l'indice de juillet 2019 à juillet 2022** : PG&E a déposé le bilan en janvier 2019 après les incendies de Californie, a été retiré du S&P 500, puis réintégré après sa sortie de faillite.

PCG étant membre **aujourd'hui**, un univers bâti sur les constituants actuels l'inclurait sur toute la période, et le traderait donc **pendant sa faillite** — en sachant, implicitement, qu'il en est ressorti vivant et que son cours a fini par se redresser. C'est du look-ahead à l'état pur, et il porte sur l'un des épisodes les plus violents du secteur sur la période.

La reconstruction point-in-time l'exclut automatiquement, sans qu'aucune règle spécifique n'ait été écrite pour ce cas. C'est le signe qu'on a corrigé la cause et non le symptôme.

9.3 Le survivorship résiduel, quantifié et orienté

Sur 38 tickers en union, **5 sont exclus** : GAS, NU, POM, TE, TEG.

Ticker	Statut	Ce qui s'est réellement passé
GAS	Aucune donnée	AGL Resources, racheté par Southern Company (2016). Le fournisseur ne sert plus rien : perte sèche.
NU	Recyclé	Northeast Utilities, renommé Eversource (ES) en 2015. Perte apparente seulement : la série ES remonte à 2014 et porte l'historique complet.
POM	Recyclé	Pepco Holdings, racheté par Exelon (2016).
TE	Recyclé	TECO Energy, racheté par Emera (2016).
TEG	Recyclé	Integrus Energy, racheté par WEC (2015).

En volume : 732 paires (photo × ticker) dans l'univers brut, 708 conservées, soit **3.3 % de pertes**. Ces pertes sont **entièrement concentrées sur 2014-2016** et **nulles à partir de janvier 2017**. Au pire snapshot, 5 noms manquent sur 31, soit environ 30 % des paires potentielles non testables.

La direction du biais — le point le plus important de la section

Les cinq noms perdus sont tous sortis de l'indice **par acquisition**, aucun par faillite. Or une OPA est précisément l'événement qui brise une relation de cointégration de la manière la plus brutale : le cours de la cible saute au prix d'offre, puis se fige, définitivement décorrélé de son secteur. Une position vendeuse sur la cible au moment de l'annonce subit une perte instantanée qui ne se résorbe **jamais** — le retour à la moyenne n'a pas lieu.

La formulation à retenir

Exclure ces cinq noms retire de l'échantillon des scénarios de perte extrême et irréversible. **Le biais résiduel surestime donc la performance de la stratégie.**

C'est le cas le plus dangereux : un biais favorable ne se signale jamais de lui-même. On n'a aucune raison de le chercher, puisque les résultats sont bons.

Conséquence pratique : le premier fold (sélection 2014-2016) est le plus exposé. L'honnêteté consiste à reporter son résultat **séparément** plutôt que de l'agréger silencieusement aux autres.

9.4 Deux zones grises assumées

- **EVRG.** Evergy est né en 2018 de la fusion de Westar et Great Plains. Le fournisseur sert un historique remontant à 2014 : ce sont les prix de Westar, le prédécesseur. C'est défendable — le prédécesseur est l'objet économique pertinent — mais il faut le savoir si un interviewer creuse.
- **SCG.** SCANA affiche un recouvrement de 0,69, inférieur à 1 : l'historique servi commence en juillet 2015 alors que la société était membre depuis 2014. L'historique est tronqué par le fournisseur, mais l'identité est cohérente. Le titre est conservé, avec moins de données que les autres.

10. Ce qui a été délibérément reporté

10.1 Le filtre de liquidité

Le plan prévoit un univers d'actions **liquides**. Aucun filtre de liquidité n'a pourtant été appliqué en Phase 1. C'est délibéré, et la raison est une fuite.

Filtrer maintenant reviendrait à calculer le volume médian sur **toute** la période 2014-2026, puis à ne garder que les titres au-dessus d'un seuil. On utiliserait donc, pour décider quoi trader en 2015, l'information « ce titre sera encore liquide en 2025 ». Cette information est fortement corrélée à la survie et au succès de l'entreprise : c'est un survivorship bias déguisé en critère technique.

Le filtre doit être recalculé à chaque fold, sur la fenêtre in-sample uniquement, exactement comme la sélection des paires. Il arrivera donc en Phase 3, au moment où la sélection elle-même est construite. C'est pour cette raison que la Phase 1 s'arrête sur un univers non filtré — ce n'est pas un oubli.

10.2 Récapitulatif des garde-fous en place

Garde-fou	Contre quoi	Où
Appartenance point-in-time	Survivorship sur la composition	<code>src/universe.py</code>
Contrôle d'identité bloquant	Recyclage de tickers	<code>validate_identity</code>
Prix total-return	Dérive de dividende dans le spread	<code>src/data.py</code>
Aucun forward-fill	Signaux générés les jours sans cotation	<code>src/data.py</code>
Dénominateur « titres en vie »	Suppression de séances valides	<code>_clean</code>
Cache disque	Non-reproductibilité de l'univers	<code>data/raw/wiki/</code>
Échec bruyant sur requête ratée	Univers silencieusement tronqué	<code>_get</code>
Décision d'univers datée	Data snooping au niveau du secteur	<code>docs/01_universe_decision.md</code>
Filtre de liquidité reporté	Survivorship déguisé en critère technique	Phase 3

11. Les deux questions posées — réponses détaillées

Question 1 — L'angle mort du contrôle d'identité

« Quel cas de recyclage passerait à travers la règle ? Et par quel mécanisme concret le P&L deviendrait-il faux sans qu'aucun test ne le détecte ? »

Le cas qui passe

Un recyclage survenant **pendant** la fenêtre d'appartenance. La règle mesure le recouvrement entre la période de cotation et la fenêtre d'appartenance ; si la société X est membre de 2014 à 2020 et disparaît en 2017, un ticker réattribué en 2018 à une société Y produirait une série continue de 2014 à 2020, recouvrant parfaitement la fenêtre. Statut : OK.

Le mécanisme de contamination du P&L

La série concaténée présenterait une **discontinuité de niveau** à la date de bascule : le prix passe de celui de X à celui de Y, sans lien économique. Trois conséquences en cascade :

1. Le test de cointégration sur la fenêtre in-sample verrait un spread avec un saut. Selon la position du saut, le test **rejetterait** à tort (le saut ressemble à une racine unitaire) ou **accepterait** à tort si le saut est suivi d'un régime stable qui ressemble à un retour à la moyenne.
2. Si la paire est sélectionnée, le z-score au moment du saut atteindrait une valeur extrême — typiquement $|z| > 5$. La stratégie ouvrirait une position **maximale** sur ce qu'elle interprète comme une opportunité exceptionnelle.
3. Cette position ne se déboucle jamais, puisque le saut n'est pas un écart temporaire mais un changement d'objet. Le P&L enregistre un gain ou une perte massive, purement fictive.

Pourquoi aucun test ne le détecte : tous les diagnostics de la Phase 7 (Sharpe, drawdown, hit rate, turnover) sont des statistiques *agrégées* calculées **sur cette même série corrompue**. Ils sont cohérents entre eux et avec les données. Rien n'est incohérent — les données sont simplement fausses. Aucune quantité de contrôles internes ne peut détecter une erreur qui affecte l'entrée du système.

Ce qui le détecterait : un identifiant pérenne (CUSIP, SEDOL, PERMNO), ou à défaut un contrôle de **discontinuité de rendement** — un rendement quotidien de plusieurs centaines de pourcents non associé à un split connu est la signature d'un changement d'entité. C'est un contrôle bon marché qu'il serait raisonnable d'ajouter.

Question 2 — L'objection sur PG&E

« Un vrai fonds n'est pas contraint par l'appartenance au S&P 500 ; il aurait pu trader PG&E pendant sa faillite. En l'excluant, tu n'as pas corrigé un biais, tu en as introduit un autre. »

L'objection est juste sur les faits et fausse sur la conclusion. Il faut accorder le premier point avant de répondre.

Ce que l'appartenance à l'indice sert réellement à représenter

On n'utilise pas l'appartenance au S&P 500 parce qu'un mandat l'imposerait. On l'utilise comme **variable de substitution, observable et point-in-time**, pour un ensemble de propriétés qu'on veut réellement imposer et qui sont difficiles à mesurer directement : capitalisation suffisante, flottant suffisant, liquidité permettant d'entrer et de sortir sans impact, et possibilité effective de **vendre à découvert** — c'est-à-dire l'existence d'un stock de titres empruntables à un coût raisonnable.

Le point décisif est ce dernier. Le pairs trading exige une jambe courte. Pendant une procédure de faillite, le titre devient extrêmement difficile et coûteux à emprunter : le coût de l'emprunt peut atteindre des dizaines de pourcents

annualisés, et le prêteur peut rappeler ses titres à tout moment, forçant un rachat au pire moment (*short squeeze*). Un backtest qui ignore ces coûts et les tarifie à zéro **surestime** massivement la performance.

La réponse en trois temps

1. **Accorder.** Oui, l'appartenance à l'indice n'est pas la contrainte réelle d'un fonds. C'est une approximation.
2. **Retourner l'argument.** C'est une approximation **conservatrice**. Elle exclut les périodes où l'exécution — en particulier l'emprunt de titres — est la plus coûteuse et la plus incertaine. En incluant PG&E pendant sa faillite avec des coûts de financement supposés normaux, je ne serais pas plus réaliste : je serais **plus optimiste**, en tarifant à zéro le risque le plus cher du marché.
3. **Nommer le vrai correctif.** La solution rigoureuse n'est pas d'inclure PG&E sans précaution, mais de modéliser explicitement le coût d'emprunt et la disponibilité du titre. Cela exige des données de *securities lending*, qui sont payantes. En leur absence, exclusion est le choix conservateur, et je le documente.

Le principe général derrière cette réponse

Face à une objection méthodologique fondée, la mauvaise réponse est de nier ; la réponse médiocre est de concéder ; **la bonne réponse est de montrer dans quel sens le choix biaise le résultat, et de préférer systématiquement le sens défavorable à la stratégie.**

C'est la ligne directrice de toute la Phase 1, et c'est le message que le projet doit transmettre en entier.

12. Glossaire

Terme	Définition
Spread	Écart entre les log-prix de deux titres, pondéré par le ratio de couverture : $\log P_A - \beta \log P_B$.
Ratio de couverture (β)	Poids de la seconde jambe. Répond à : combien vendre de B pour un dollar de A.
$I(0) / I(1)$	Série stationnaire / série dont seule la différence première est stationnaire. Un prix d'action est typiquement $I(1)$.
Stationnarité	Propriété d'une série dont la loi ne dépend pas du temps : elle oscille autour d'une moyenne fixe au lieu de dériver.
Cointégration	Existence d'une combinaison linéaire $I(0)$ de séries $I(1)$. Formalise l'idée d'une relation d'équilibre de long terme.
ADF	Test de Dickey-Fuller augmenté. Teste la présence d'une racine unitaire ; on l'applique au résidu pour tester sa stationnarité.
Look-ahead	Utilisation, pour décider à la date t , d'une information non disponible à t . Gonfle la performance sans se signaler.
Survivorship bias	Forme de look-ahead portant sur l'existence : ne retenir que les sociétés ayant survécu jusqu'à aujourd'hui.
Point-in-time	Donnée reconstruite telle qu'elle était observable à la date considérée, et non telle qu'on la connaît aujourd'hui.
Walk-forward	Protocole de validation où sélection et évaluation se succèdent dans le temps, sans jamais se chevaucher.
In-sample / Out-of-sample	Période de sélection et d'estimation / période de test, postérieure et strictement disjointe.
Total-return	Série de prix ajustée des splits et des dividendes réinvestis.
Forward-fill	Remplissage d'une valeur manquante par la dernière valeur connue. Proscrit ici (section 6.2).
Merchant (producteur)	Producteur d'électricité vendant au prix de marché, par opposition à un régulé dont les tarifs sont fixés.
GICS	Nomenclature sectorielle standard. Utilities est le secteur de niveau 1 retenu ici.
Recyclage de ticker	Réattribution d'un symbole boursier à une autre société après la disparition de la première.